

Data augmentation appliquée aux images

Cours d'Automne - Nassima, Fabrice, Maéva
21 novembre 2025

Plan de la présentation

01

Introduction

02

Méthodologie

03

Illustration

04

Ancrage en sciences du vivant

05

Conclusion

06

Ouverture

Introduction

- ML + classification d'images = besoin de beaucoup de données
- Data augmentation → augmente la diversité → limite overfitting
- Dataset utilisé : Animals-10 (10 classes)
- Objectif → tester 3 méthodes et comparer leurs performances



Méthodologie

Dépend de la **nature des données** (images, texte, etc.).

Augmentation d'images

Historiquement, la DA a été appliquée aux tâches de vision par ordinateur (Computer Vision) :

- **Classification d'images** : Attribuer une étiquette à une image.
- **Détection d'objets** : Identifier et localiser des objets spécifiques dans une image.
- **Segmentation d'images** : Diviser une image en différentes zones ou objets distincts

□ Déformation des données (**Data Warping**) :

Les méthodes qui transforment l'image originale en conservant son étiquette (**label-preserving**), c'est-à-dire que l'image modifiée conserve le même label de classification que l'original

- Transformations géométriques,
- Transformations de l'espace couleur,
- Filtres à noyau,
- Effacement aléatoire.

□ Suréchantillonnage (**Oversampling**)

Ces méthodes génèrent de nouvelles instances d'entraînement entièrement nouvelles (**synthétiques**) en utilisant des modèles d'apprentissage profond ou en combinant les données existantes

- Mélange d'images

Méthodologie Déformation des données (Data Warping)

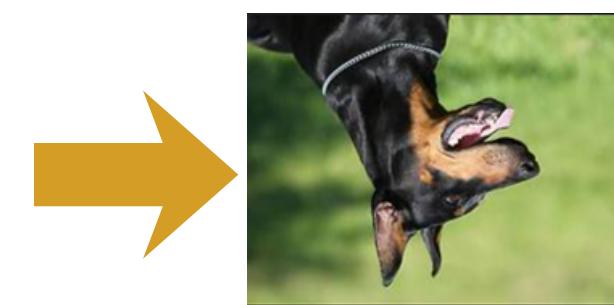
Transformations Géométriques (Geometric transformations) :



Retournement (Flipping)



Retournement vertical



Rotation



Translation



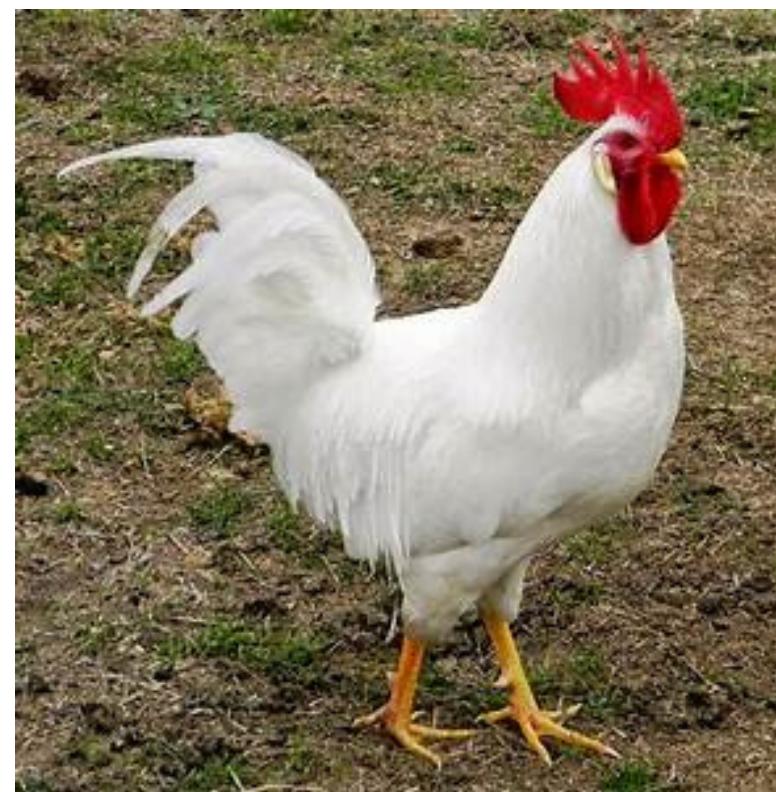
Recadrage (Cropping)



Transformations Affines Générales

Méthode d'augmentation : Distortion des couleurs

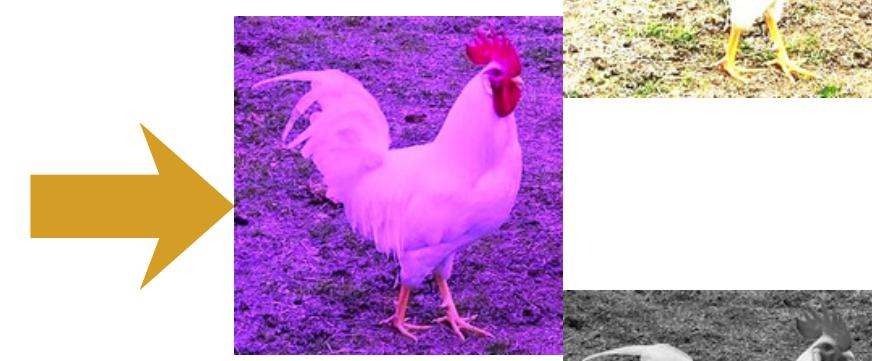
Objectif : améliorer la robustesse du modèle face aux variations d'éclairage, de teinte et de saturation



Variations de luminosité



Variation de teinte



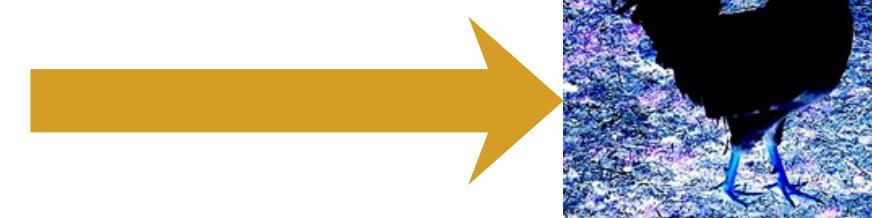
Passage en noir et blanc



Saturation des images



Manipulation des canaux RVB



Méthodologie

Effacement aléatoire (Random Erasing)

Objectif :

Masquer aléatoire de zones de l'image pour pousser le modèle à chercher des caractéristiques plus robustes.

Spécifiquement conçue pour combattre les défis de reconnaissance d'images dus à l'occlusion.

Principe et Fonctionnement :

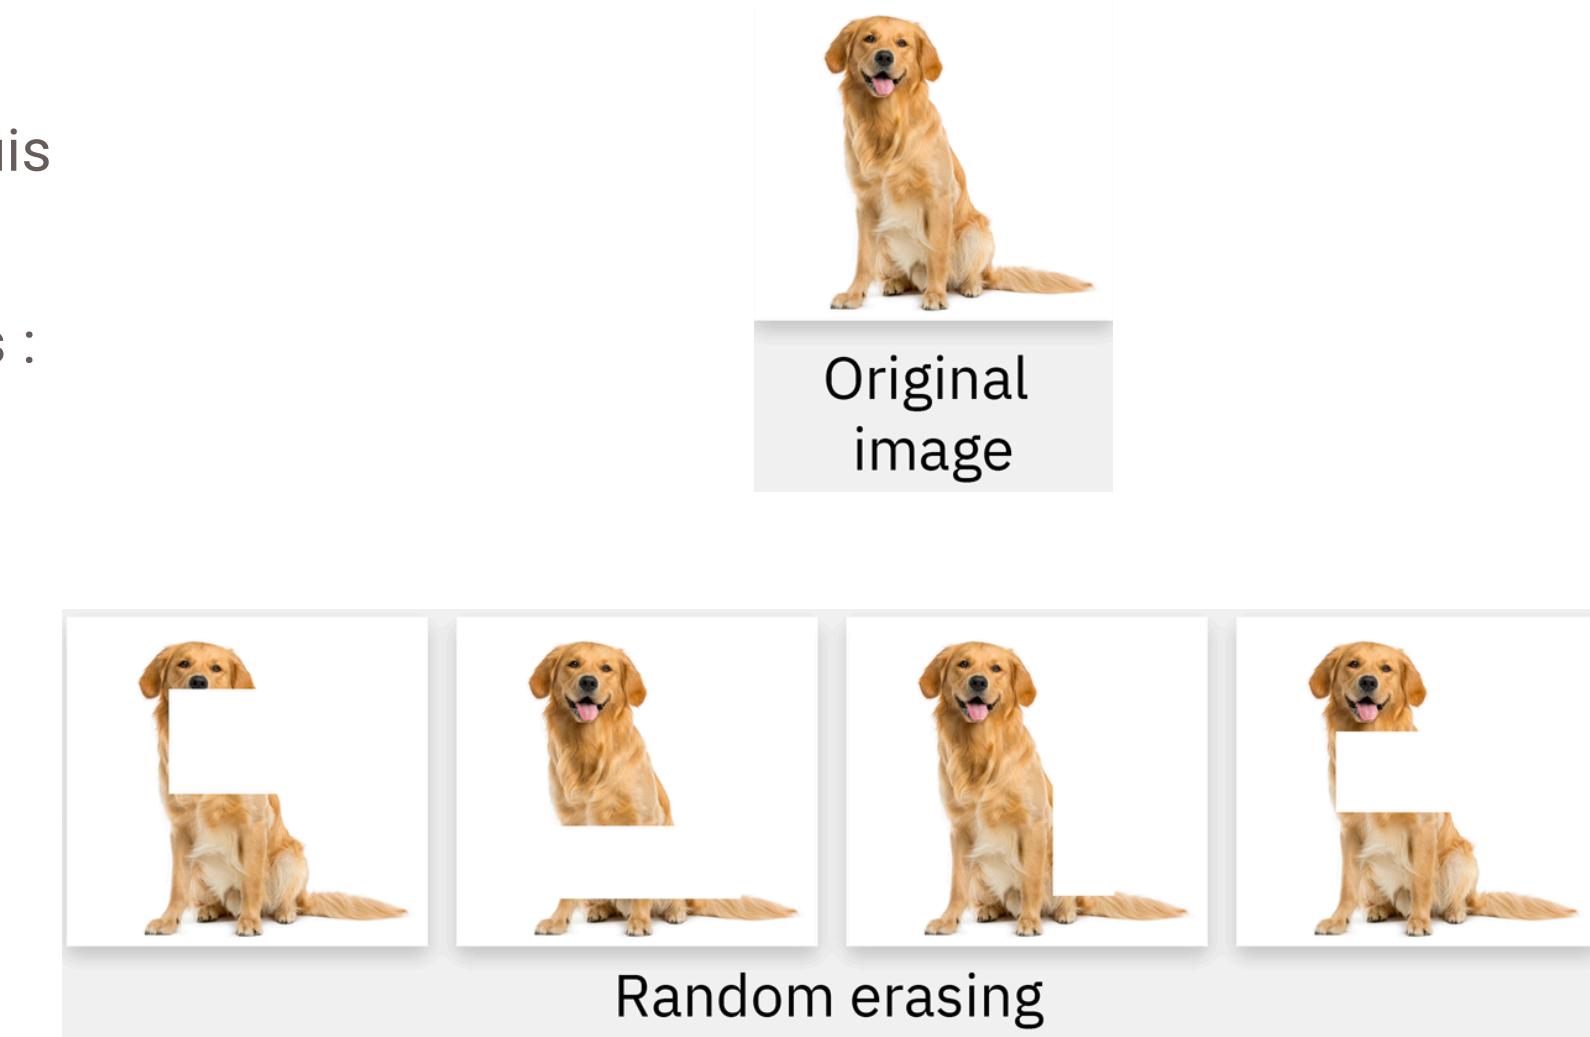
- Sélection aléatoire d'un patch de taille $n \times m$ dans l'image, puis
- Masquage ou effacement de cette zone.
- Remplissage de la zone effacée par des valeurs spécifiques :
 - 0s (noir).
 - 255s (blanc).
 - Des valeurs de pixels moyennes.

Avantages :

- Prévention du Surapprentissage
- Amélioration de la Robustesse et de la Performance

Limites :

- Perte d'étiquette (Effacer une partie d'un chiffre ou d'un logo dans une image pourrait rendre l'objet méconnaissable.)



Méthodologie

Filtres à Noyau (Kernel Filters)

Objectif

Introduire des variations dans l'image pour rendre le modèle plus robuste lors de l'entraînement.

Principe de Fonctionnement

- Les filtres à noyau utilisent une matrice de taille $n \times n$ (le noyau) qui "glisse" sur l'image pour manipuler localement les pixels.
- La convolution est l'opération principale, où chaque valeur de pixel de l'image est modifiée en fonction des valeurs du noyau.

Applications Typiques

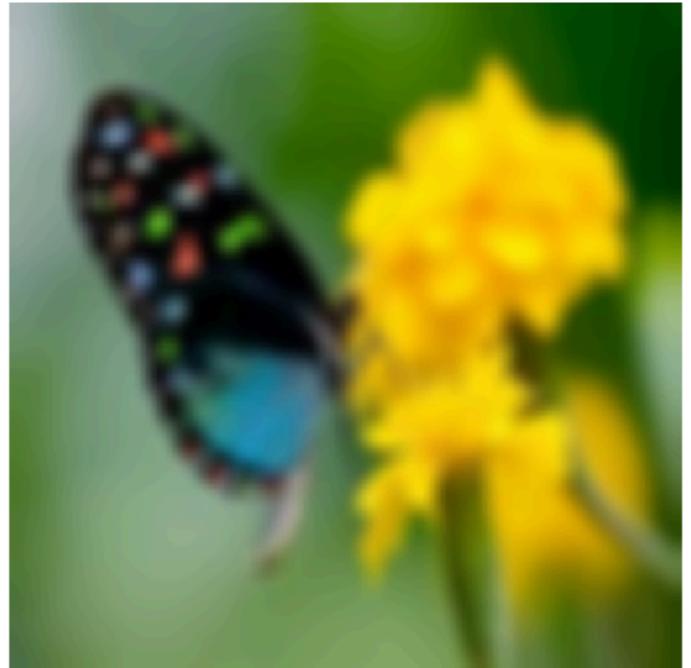
- **Flou** (Blurring) : Rendre l'image floue pour aider le modèle à mieux gérer le flou de mouvement. (Ex: Flou Gaussien)

Flou Gaussien

Original - butterfly



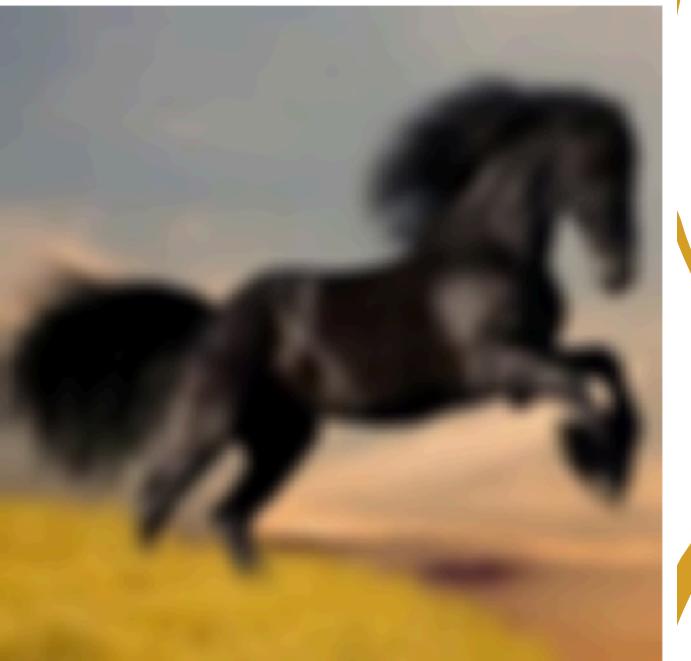
Augmentée (GaussianBlur) - butterfly



Original - horse



Augmentée (GaussianBlur) - horse



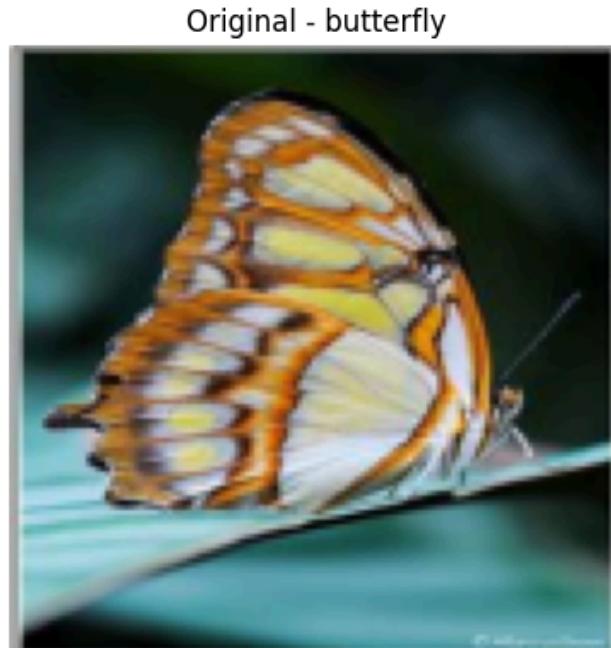
Méthodologie

Filtres à Noyau (Kernel Filters)

- **Affûtage (Sharpening)** : Accentue les détails des bords pour mieux capturer les objets d'intérêt, comme avec des filtres de contraste élevé.



- **Regularization (PatchShuffle)**: Permuter aléatoirement les valeurs de pixels dans une fenêtre glissante de taille $n \times n$.



Méthode d'augmentation : Retournement horizontal



PRINCIPE

- Effet miroir
- Probabilité : 50%
- Invariance gauche/droite

PROTOCOLE

- 1000 img/classe
- Split : 80/10/10
- CNN 3 couches
- 20 époques

IMPLÉMENTATION

- RandomHorizontalFlip($p=0.5$)

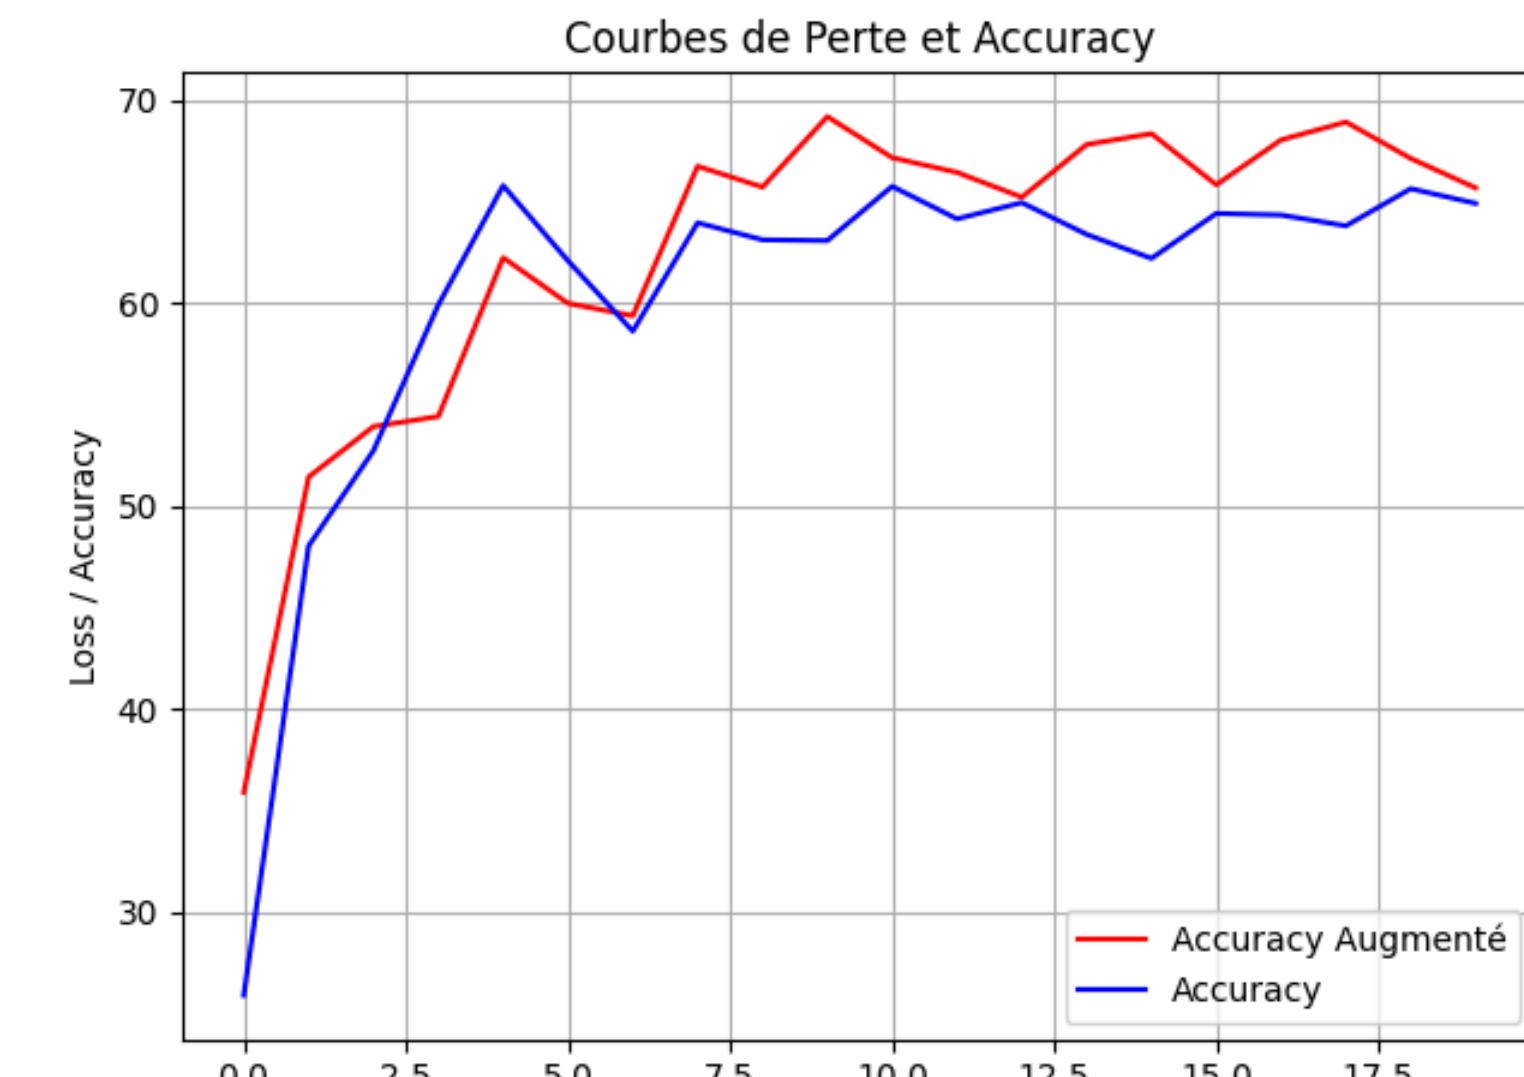
HYPOTHÈSE

Le flip horizontal repose sur l'hypothèse que l'orientation ne modifie pas la classe ; il vise donc à améliorer la généralisation.

Illustration -- Retournement Horizontal

Résultats

Métrique	Non Augmenté	Augmenté (Flip)	Meilleur Modèle
Accuracy	64.4%	64.6%	Augmenté (Très légère meilleur)
Perte (Loss)	2.4876	1.7955	Augmenté (Significativement plus faible)
F1 Score (Macro)	0.6039	0.6147	Augmenté (meilleur, plus robuste)
Precision	0.6207	0.6397	Augmenté (meilleur)
Recall	0.5941	0.6203	Augmenté (meilleur)



Le Flip Horizontal améliore significativement la perte et les métriques de classification, prouvant son efficacité pour cette tâche.

Méthode d'augmentation : Passage en noir et blanc



PRINCIPE

- Retirer la couleur
- Probabilité : 0.5%

IMPLÉMENTATION

- Grayscale()

PROTOCOLE

- 26179 images; 10 classes
- Split : 80/10/10
- CNN 3 couches
- 20 époques

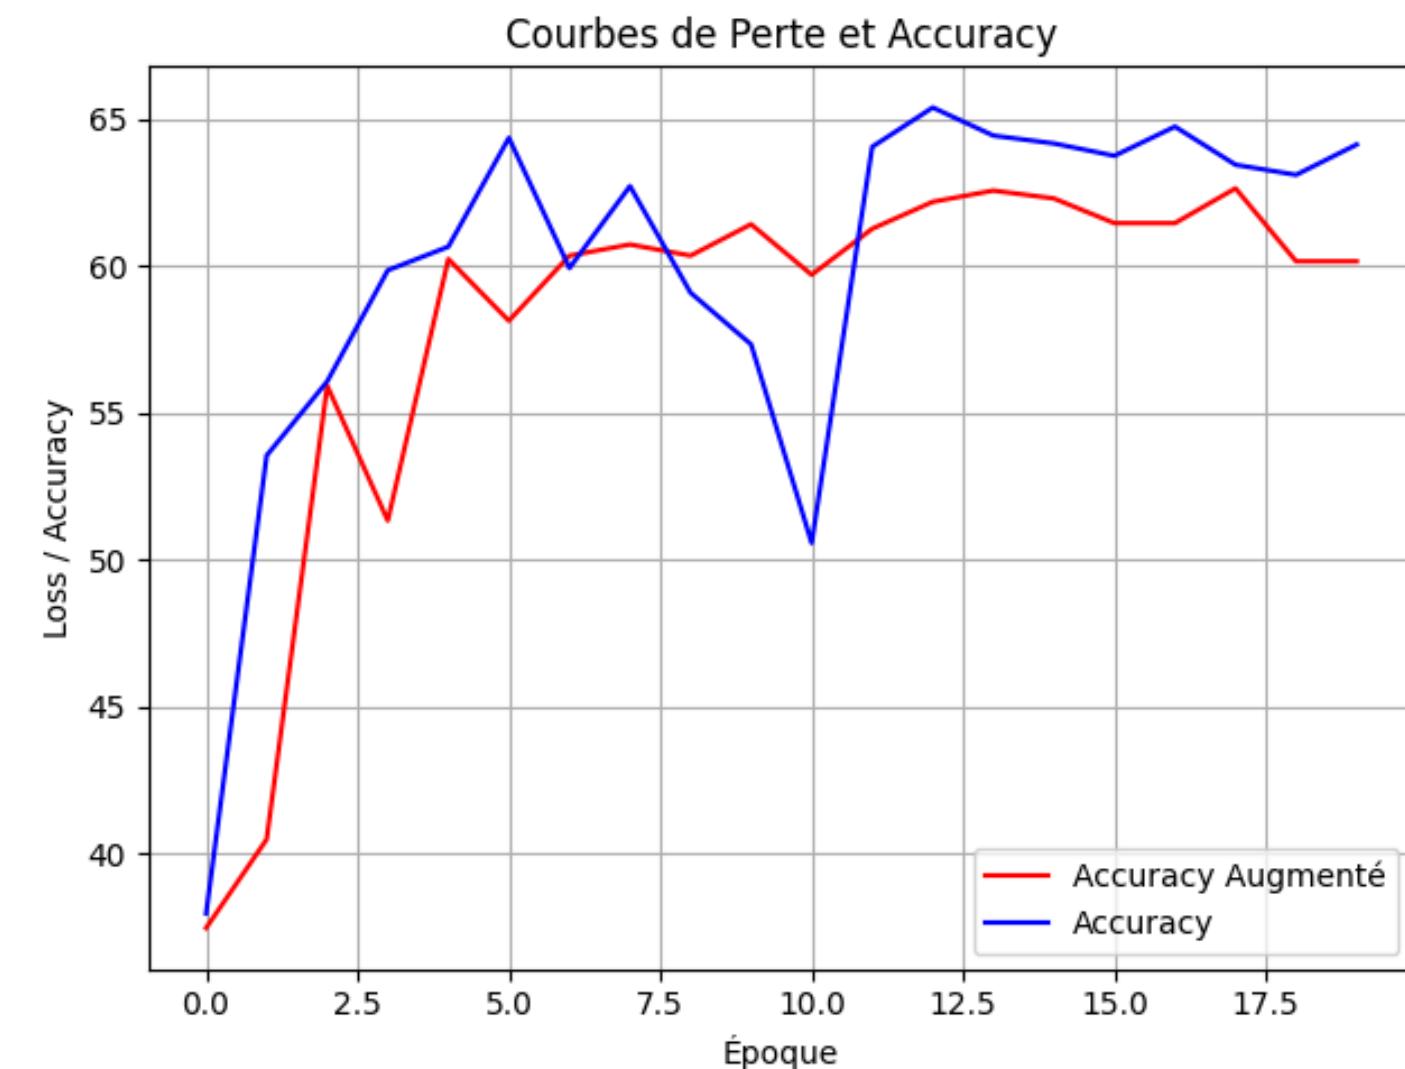
HYPOTHÈSE

Le passage en noir et blanc repose sur l'hypothèse que la présence de couleur ne modifie pas la classe ; il vise donc à améliorer la généralisation.

Illustration -- Passage en noir et blanc

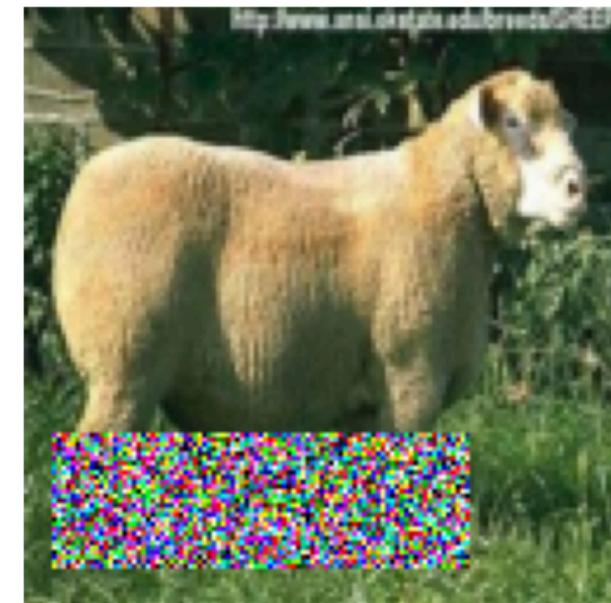
Résultats

Métrique	Non Augmenté	Augmenté (noir et blanc)	Meilleur Modèle
Accuracy	63.9%	60.5%	Non Augmenté (Très légère différence)
Perte (Loss)	2.496723	2.55188	Non Augmenté (plus faible)
F1 Score (Macro)	0.6169	0.5800	Augmenté (Légèrement meilleur)
Precision	0.6267	0.6182	Augmenté (Très légèrement meilleur)
Recall	0.6148	0.5613	Augmenté (Légèrement meilleur)



- Pas d'amélioration visible sur cet entraînement

Illustration -- Effacement aléatoire



PRINCIPE

- Suppression de zone
- Probabilité : 0.5

PROTOCOLE

- 26179 images, 10 classes
- Split : 80/10/10
- CNN 3 couches
- 20 époques

IMPLÉMENTATION (Pytorch)

```
RANDOM_ERASING_TRANSFORM = transforms.RandomErasing(  
    p=0.5,           # 50% de chance d'appliquer la suppression  
    scale=(0.02, 0.33), # Taille de la zone  
    ratio=(0.3, 3.3),  # Ratio H/L  
    value='random'   # Remplir la zone avec des valeurs aléatoires  
)
```

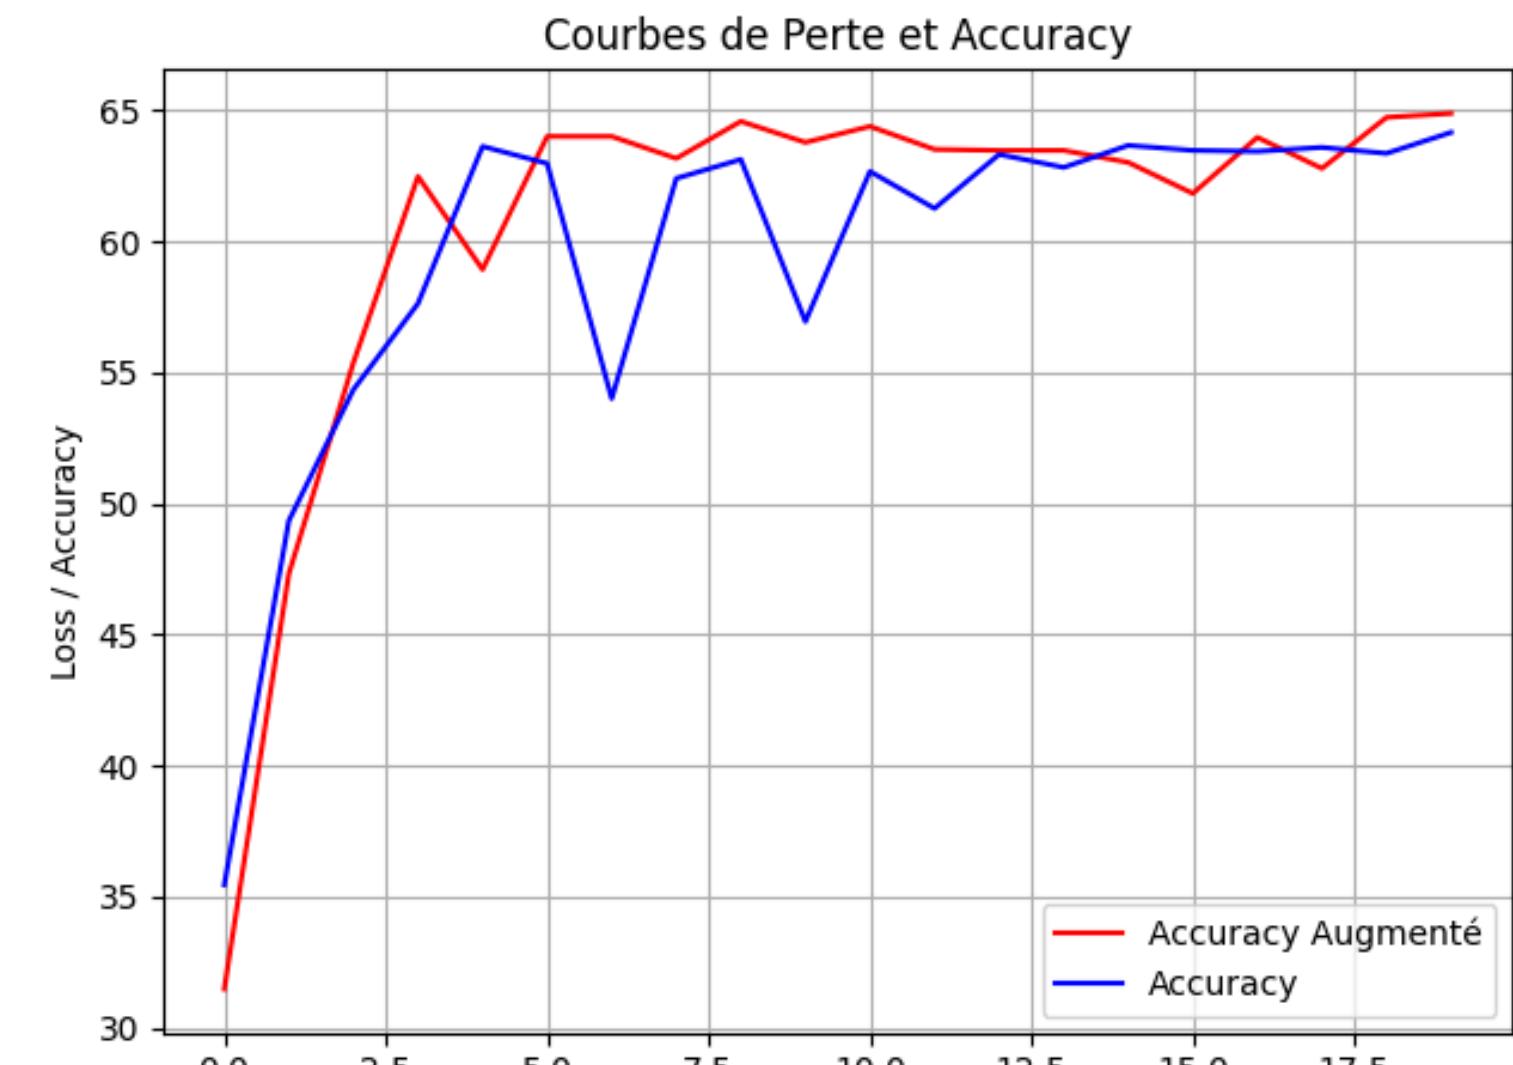
HYPOTHÈSE

Les caractéristiques importantes d'une image ne sont pas confinées à une petite zone

Illustration -- Effacement aléatoire

Résultats

Métrique	Non Augmenté	Augmenté (Erasing)	Meilleur Modèle
Accuracy	63.4%	63.3%	Non Augmenté (Très légère différence)
Perte (Loss)	2.0286	2.4937	Non Augmenté (plus faible)
F1 Score (Macro)	0.5966	0.6043	Augmenté (Légèrement meilleur)
Precision	0.6268	0.6273	Augmenté (Très légèrement meilleur)
Recall	0.5896	0.5960	Augmenté (Légèrement meilleur)



- Modèle **Non Augmenté** : Moins de perte de test (2.03 vs 2.49), indiquant des prédictions plus sûres.
- Modèle **Augmenté** : Légèrement meilleur F1 Score (0.6043 vs 0.5966) grâce à un meilleur équilibre Precision/Recall. 15

Limites de la DA

Limites Conceptuelles et de Réalisme

- Perte de Plausibilité Sémantique
- Effet Contre-Product

Limites d'Implémentation et de Performance

- Coût Computationnel
- Complexité du Pipeline

Limites d'Efficacité et d'Évaluation

- Ne Remplace Pas les Vraies Données
- Risque de Augmentation Overfitting
- Évaluation Délicate

La Data Augmentation (DA) en Sciences du Vivant

Agronomie : Maladies Végétales

- **Défi :** Annotation coûteuse et petite taille des ensembles de données (ex. segmentation de la tavelure du pommier).
- **Approches de DA :**

Génération des variations réalistes des images de plantes, améliorant ainsi la détection des maladies et la segmentation des infections végétales dans des ensembles de données souvent limités.

- **Intérêt :**
 - Amélioration de la performance de segmentation jusqu'à 17%.
 - Précision de 97,61% pour les stress foliaires du soja.

(Douarre et al., 2019).

Novel data augmentation strategies to boost supervised segmentation of plant disease.
Computers and Electronics in Agriculture

(Saleem et al., 2024)

Class-specific data augmentation for plant stress classification. *The Plant Phenome Journal*.

La Data Augmentation (DA) en Sciences du Vivant

Santé Humaine : Reconstruction IRM

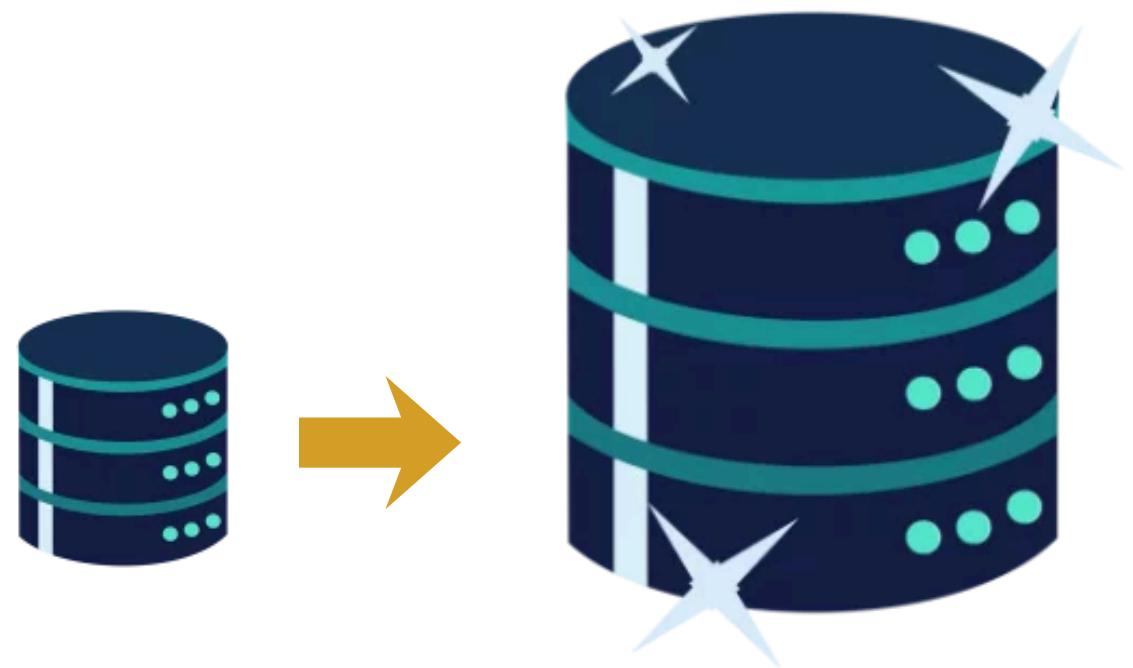
- **Défi :** Sous-échantillonnage des données pour accélérer l'acquisition IRM, créant un manque de données d'entraînement.
- **Approches de DA :**

Augmenter la quantité de données d'entraînement pour des modèles de reconstruction d'IRM, améliorant ainsi la qualité des images reconstruites à partir de données sous-échantillonnées.

- **Résultats :**
 - Amélioration significative de la reconstruction, jusqu'à l'état de l'art avec moins de données d'entraînement.
 - Prévention du surapprentissage et meilleure généralisation aux scanners non vus.

Conclusion

- Méthodes plus ou moins efficaces
- Augmente le nombre de données
- Augmente la robustesse du modèle
- On peut imaginer combiner plusieurs méthodes pour augmenter davantage



Ouverture vers d'autres augmentations...

Augmentation de données textuelles

- brassage de phrases
- position des mots
- remplacement par synonymes ou aléatoires
- suppression de mots

Et même



Augmentation de séries temporelles :

- séries temporelles par interpolation

Bibliographie

- Barbedo, J. G. A.** (2025). A review of artificial intelligence techniques for wheat crop monitoring and management. *Agronomy*, 15(5), 1157. <https://doi.org/10.3390/agronomy15051157>
- Diallo, M. B., Li, Y., Chukwuka, O. S., Boamah, S., Gao, Y., Kana Kone, M. M., Rocho, G., & Wei, L.** (2025). Enhanced-RICAP: a novel data augmentation strategy for improved deep learning-based plant disease identification and mobile diagnosis. *Frontiers in Plant Science*, 16, 1646611. <https://doi.org/10.3389/fpls.2025.1646611>
- Douarre, C., Crispim-Junior, C. F., Gelibert, A., Tougne, L., & Rousseau, D.** (2019). Novel data augmentation strategies to boost supervised segmentation of plant disease. *Computers and Electronics in Agriculture*, 165, 104967. <https://doi.org/10.1016/j.compag.2019.104967>
- Fabian, Z., Heckel, R., & Soltanolkotabi, M.** (2021). Data augmentation for deep learning based accelerated MRI reconstruction with limited data. In Proceedings of the 38th International Conference on Machine Learning (PMLR 139).
- Kebaili, A., Lapuyade-Lahorgue, J., & Ruan, S.** (2023). Deep learning approaches for data augmentation in medical imaging: A review. *Journal of Imaging*, 9(4), 81. <https://doi.org/10.3390/jimaging9040081>
- Lashgari, E., Liang, D., & Maoz, U. (2020).** Data augmentation for deep-learning-based electroencephalography. *Journal of Neuroscience Methods*, 346, 108885. <https://doi.org/10.1016/j.jneumeth.2020.108885>
- Li, G., Huang, Y., Chen, Z., Zhao, Y., Linhoss, J., & Purswell, J. L. (2021).** Practices and applications of convolutional neural network-based computer vision systems in animal farming: A review. *Sensors*, 21(4), 1492. <https://doi.org/10.3390/s21041492>
- Saleem, N., Balu, A., Jubery, T. Z., Singh, A., Singh, A. K., Sarkar, S., & Ganapathysubramanian, B.** (2024). Class-specific data augmentation for plant stress classification. *The Plant Phenome Journal*, 7, e20112. <https://doi.org/10.1002/ppj2.20112>
- Shorten, C., & Khoshgoftaar, T. M.** (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 1–48.

Merci pour
votre attention

